

大类资产配置

2017-4-19

金融工程 | 专题报告

大类资产配置之机器学习应用于股票资产的趋势预测

报告要点

■ 大类资产配置系统简介

资产配置按照配置目标、配置周期、收益预期及风险偏好等可以分为超长期资产配置、战略性资产配置、战术性资产配置、动态资产配置和保底资产配置。每一种配置系统之下，各类资产走势的影响因素都不尽相同，目前国内市场较为关注的是配置周期相对较短的战术性资产配置和动态资产配置。

■ 三种机器学习方法应用于股票类资产的趋势判断

进行大类资产配置时对每一类别的资产的分析十分重要，本篇主要是针对股票类资产进行分析，使用 logistic 模型、人工神经网络模型及支持向量机三种模型对股票类资产短期走势进行预测。选取不同的输入指标、训练期等进行预测和比较，对于沪深 300 的月度走势预测准确度最高达到 65%，最佳配适模型是训练期为 36 个月的 logistic 模型。

■ 股票走势多分类下模型的预测效果

使用机器学习模型还有一个优势就是可以将股票走势按照涨跌的幅度划分为更细致的类型，分别对划分成 4 类（大幅上涨、小幅上涨、大幅下跌、小幅下跌）和六类（幅度分得更细）两种情况下的样本进行预测。四分类下预测准确度最好的模型仍然是训练期为 36 个月的 logistic 模型，胜率为 64%，并且获取了比二分类下更高的超额收益率。六分类的预测效果不佳，主要原因是分成六类之后每一类别下的样本数量过少。

■ 趋势判断结果运用于其他常见股票指数

将前面沪深 300 的预测结果用于中证 500 和中证 1000，在四分类下对中证 500 和中证 1000 预测的超额收益率分别为 19.4% 和 19.18%。简单的通过三种指数等权的方式对加入趋势判断后的效果进行测算，夏普比率及 Calmar 比率都有了显著性的提高，说明在进行趋势判断后再采取不同风格轮动方式，可以起到很好的提高收益平滑波动的作用。

分析师 覃川桃

☎ 021-68751782

✉ qinct@cjsc.com

执业证书编号：S0490513030001

联系人 陈洁敏

☎ 021-68751787

✉ chenjm5@cjsc.com

联系人 杨靖凤

☎ (8621) 68751636

✉ yangjf@cjsc.com.cn

相关研究

《2017 年指数分红预测与基差监控》2017-3-27

《长江金工高频识途系列（一）基于买入行为构建情绪因子》2017-3-10

《FOF 之基金持仓的相关稳定性研究》2017-2-13

风险提示：

1. 最优模型和参数均是针对本文所选样本，并不能保证其在其他样本同样有效；
2. 历史业绩回测不代表未来收益。

目录

大类资产配置系统简介	4
机器学习应用于股票趋势判断	5
机器学习方法简介	8
机器学习预测的流程	8
三种模型的特点简介	9
MNL 模型	9
人工神经网络 (ANN) 模型	10
支持向量机 (SVM) 模型	11
预测的结果展示和分析	13
模型的输入指标及参数设定	13
模型的预测结果	14
显著性检验	15
模型的显著性	15
输入指标的显著性	16
多分类下的模型预测效果	17
四分类下的预测效果	17
六分类下的预测效果	19
其他股票指数上的预测效果	19

图表目录

图 1: S&P500 指数价格走势和历史 PE	7
图 2: 上证综指价格走势和历史 PE	7
图 3: 监督学习预测股票走势的流程图	8
图 4: MNL 模型中使用的 logit 曲线	9
图 5: logistic 模型预测股票走势的流程图	10
图 6: BP 神经网络模型预测股票走势的流程图	11
图 7: SVM 模型分类原理示意图	12
图 8: SVM 模型在非线性可分下的映射逻辑	13
图 9: SVM 模型预测区间内净值曲线走势	14
图 10: MNL 模型训练长度 30 个月时的净值曲线走势	15
图 11: MNL 模型训练长度 36 个月时的净值曲线走势	15
图 12: 三种模型的 ROC 曲线	16
图 13: 不同指标类别的显著性水平	17
图 14: 显著性排名前十的指标	17

图 15：四分类下 ANN 模型训练长度 30 个月时的预测效果	18
图 16：四分类下 SVM 模型训练长度 12 个月时的预测效果	18
图 17：四分类下 ANN 模型训练长度 36 个月时的预测效果	18
图 18：四分类下 MNL 模型训练长度 36 个月时的预测效果	18
表 1：大类资产配置方法概述	5
表 2：影响股票价格的因素	6
表 3：模型参数的选择	14
表 4：预测准确率最高的五组结果	14
表 5：最优组的分年情况	15
表 6：三种模型的 AUC 值展示	16
表 7：预测准确率最高的五组结果	17
表 8：最优组的分年情况	18
表 9：预测准确率最高的五组结果	19
表 10：二分类下对中证 500 和中证 1000 的预测效果	19
表 11：四分类下对中证 500 和中证 1000 的预测效果	20
表 12：加入趋势判断后三种指数等权重组合的效果	20

本篇是长江金工大类资产配置系列的第二篇报告，在第一篇报告中我们对风险平价模型进行了改良。为了解决模型在国内使用的时候存在一些水土不服及配置固化等问题，引入了风险预算的概念，尝试在预期股票资产的收益率较高的时候增加股票资产对于组合的风险贡献，从而提高股票资产的权重。

在调整股票的风险贡献度时需要解决主要问题有：1、衡量各资产之间的风险相关性度量；2、设置调整资产风险贡献度的标准。与所有其他配置模型例如马科维茨均值方差模型和 Black-Litterman 模型一样，本质上讲还是对资产的预期收益率及波动率的估计。

此篇报告将会承接前一篇，首先是对大类资产配置的方法做一个系统性的梳理，其次是在整个系统之中选择适合国内配置需求的配置方法做细致深入的研究；对不同类别的资产收益率和波动率做出更为细致的估计和测算，此篇主要是研究对于权益类资产走势的预测，具体做法是采用机器学习，输入估值、宏观和利率三大指标，通过多个模型的测算和比较，对国内股票收益率的方向做出预测，最终月度预测胜率达到了 65%；同时，也对于国内权益类资产做了细分，将在沪深 300 上的预测效果应用到了中证 500 和中证 1000 两种不同风格的股票指数上，均取得了较好的预测效果。

针对其他常见资产例如债券和商品，也将在之后的报告中做出具体分析，再结合此篇中对于股票资产的预测，运用配置模型，来求取各个资产的最优权重。

大类资产配置系统简介

资产配置按照配置目标、配置周期、收益预期及风险偏好等可以分为以下五类：

超长期资产配置 (Secular Asset Allocation) 指的是配置周期长达十年及以上的资金配置方式，追求的是长期稳定的回报。在此种级别的时间周期中，各资产的收益率跟经济体的潜在发展增速（包括企业盈利及名义 GDP 增速等）、社会的人口结构等密切相关，在持有期初各个资产之间的权重一经确定，将不会进行频繁的调整，一般保险及养老金管理机构等才会有相关需求。

战略性资产配置 (Strategic Asset Allocation) 是针对于有较长配置周期在三到七年的资金的配置方式，投资初期一旦确定各资产投资比例后，将忽略资产短期的波动影响。初期各资产配置比例，对于传统资产，可依据资产当前估值水平在历史估值的分位确定，充分利用估值在此时间周期内表现出的均值回复现象。除此之外也可以持有一些流动性较低的资产例如股权、房地产等，获取中长期内的流动性风险溢价。例如美国耶鲁大学的捐赠管理基金就是在预留一部分流动性的前提下，对于剩余资金进行长期战略性配置并进行大量另类资产投资。

战术性资产配置 (Tactical Asset Allocation) 战略性资产配置策略时间周期较长，实际投资中更为常见的是根据资本市场环境及经济条件对于资产配置进行动态调整，配置周期从半年到三年。把握经济周期，根据经济所处的不同阶段，灵活调整和配置资产显得十分重要。宏观经济判断依据于长期以来对宏观数据的搜集、处理和分析，需要有长期的经验积累及独立的思考和判断力。战术性资产配置相较于战略性资产配置是更为积极的一种配置方式，也是目前国内外使用得最为广泛的资产配置方法之一。

动态资产配置 (Dynamic Asset Allocation) 动态资产配置主要是针对于短期投资，简单而言就是增持或者买入预期收益高的资产，卖出或者减持预期收益低的资产，以获取较高超额收益率为目标。周期为一个月到半年。根据资产的量价进行择时加上洞察市场

情绪来调整各资产的配比，当然宏观判断也很重要，但是此时宏观指标的增量信息参考意义更大。

保底资产配置 (Insured Asset Allocation) 保底资产配置策略比较适合风险厌恶型的投资者，因为其在投资组合构建前设定了投资组合的保底收益率，只有组合的收益超过保底收益后，才能采取积极的管理方式进行资产权重的调整以获取更高的超额收益率。相反，如果组合的价值降低到组合保底价值，就必须对于风险资产进行降仓操作，主要投资于无风险资产确保资产组合总价值无下行风险。

表 1：大类资产配置方法概述

类别	配置周期	配置依据
超长期资产配置	十年及以上	经济体发展增速、社会的人口结构等
战略性资产配置	三到七年	资产的估值及流动性风险补偿
战术性资产配置	半年到三年	宏观经济周期及资产周期的判断
动态资产配置	一个月到半年	量价信息、市场情绪、宏观指标增量等
保底资产配置	周期不定	根据配置周期综合考量

资料来源：长江证券研究所

表 1 对于几种常见分类方式做了汇总，实际中并没有严格的时间界限定义，各种配置方法只是投资管理过程中可以运用到的基本逻辑和思路，并不存在优劣之分，实际应用的时候需要综合考量，也可以将各种配置方法结合起来使用。

机器学习应用于股票趋势判断

目前国内大部分投资者的配置周期和配置需求集中在战术性资产配置和动态资产配置，本篇报告跟上篇一样也将着重于使用动态资产配置方法。此部分针对权益类资产，对国内股票资产月度走势进行预测，预测具体的涨跌幅度或点位准确度较低，也无太大意义，因此只对月度方向进行预测。

在第一篇资产配置报告中，我们看到了遵循股票收益率的动量和反转调整股票权重的威力，使得组合的收益率从 5% 左右的水平提升到了 14%。但是动量和反转仅仅反映了过去一段时间内股票价格包含的信息，获取的信息非常有限，还需要结合市场情绪及宏观指标才能对未来的收益率起到预判作用。我们综合考虑了影响股票收益率的因素，大致归类成以下类别：估值因素、利率因素和宏观经济因素。结合这些因素对一段时间内股票收益率的方向做出预测。

表 2：影响股票价格的因素

指标类别	细分指标	指标含义	频率	数据设置
宏观因素	GDP	国民经济生产总值（当季同比）	季度	滞后一月
	CPI	消费者物价指数	月度	滞后一月
	PPI	生产者物价指数	月度	滞后一月
	Capital Investment	固定资产投资完成额（累计同比）	月度	滞后一月
	Consumption	社会消费品零售总额	月度	滞后一月
	Boom Lead	宏观经济景气指数（先行指数）	月度	滞后一月
	PMI	采购经理人指数	月度	滞后一月
利率因素	M1	广义货币 M1 同比	月度	滞后一月
	M2	广义货币 M2 同比	月度	滞后一月
	YTM1Y	1 年期国债到期收益率	日度	月末
	YTM5Y	5 年期国债到期收益率	日度	月末
	YTM10Y	10 年期国债到期收益率	日度	月末
估值因素	PE	市盈率	日度	月末
	PB	市净率	日度	月末
	PCF	市现率	日度	月末
	PS	市销率	日度	月末
	Dividend	分红率	日度	月末


资料来源：长江证券研究所，DisplaySearch

为了避免过度拟合及共线性问题，我们目前纳入到每种类别中的指标是最基础和最常见的几种指标。之后也会不断的加入新指标进行、测算和扩充。考虑到指标的频率以及公布时间滞后性，我们在进行当月预测的时候使用上个月月末能够获取的数据。当月的宏观指标例如 CPI 等往往在次月中下旬公布，此时会选择滞后一个月的月末数据。

宏观因素和利率因素对于股票和债券资产的影响均较大，但是很多时候这种影响关系是非线性的，在不同时期起作用的因素并不相同，影响的方向也较为复杂。

估值指标的作用首先是在较长期限内具有均值回复特征，这个特点在国外发达国家的股票市场表现十分明显，但是在短期，其更多是反映出股票价格及公司盈利水平，效果类似于使用股价短期的动量和反转效应。在国内股市，由于市场不够成熟，有效可参考的历史区间较短，估值指标的影响也并非呈线性。


图 1：S&P500 指数价格走势和历史 PE



资料来源：Bloomberg, 长江证券研究所

上图是美国标普指数的价格走势和历史 PE，直线是估算的 PE 回归趋势线，有略微向上增长的一个斜率。长期看来有均值回复的特征。

图 2：沪深价格走势图和历史 PE



资料来源：Wind, 长江证券研究所

上证综指的走势及估值见上图，可以看出并未出现明显均值回复现象，在 05 年前的走势跟股指走势非常一致，05 年前后估值绝对值出现了较大区别，所以整段区间拿来分析的时候中间的影响并不能用简单的线性模型来解释。

针对各个指标的影响形式，在此浅尝机器学习方法来进行股票资产走势的预测。

机器学习方法简介

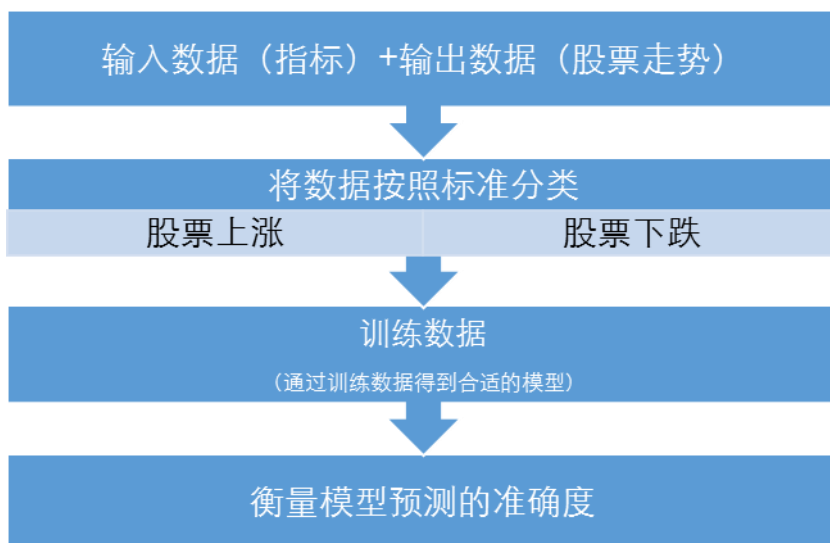
将机器学习的方法应用于股票走势的预测在国外已经做过很多成熟的研究，也取得了较好的效果，但大多是针对成熟市场并且只使用了宏观经济、利率指标。本文中我们将使用前面提到的所有指标包括估值、股息率类指标等采取三种机器学习方法：logistic 模型（MNL）、人工神经网络模型（ANN）、支持向量机模型（SVM），进行预测和比较，选择出最合适的模型来应用。

机器学习预测的流程

和我们所有传统的数学模型和量化研究方法类似，机器学习也是从历史数据总结经验，本质上是一种统计和优化的方法，通过训练集内的数据的规律，进行自动优化的计算机程序。无论多么复杂的机器学习模型，都可以看作是一个信息的分解、提取、再整合的过程，通过最基本的核函数，可以将空间内任何复杂的映射关系表现出来。

我们选择的三种模型是属于机器学习中的监督学习，监督学习的训练集要求是包括输入和输出，也可以说是特征和目标，训练集是为了模拟输入输出间的映射关系，并且将这种关系扩展到训练集外。

图 3：监督学习预测股票走势的流程图



资料来源：Wind，长江证券研究所

三种模型的特点简介

上面一部分简单描述机器学习用于测股票走势的核心和流程，这一部分将分开介绍一下本文用到的三种模型的原理及各自预测时特点。

MNL 模型

Logistic 模型可以认为是一个单层的神经网络，一般用于来进行线性可分的分类。MNL 模型是 logistic 模型中最基础的一种，可以进行多类别的预测。

将股票的月度收益率方向分成 J ($i = 1, 2, \dots, J$) 个选项, 每一个选项的效用可以表示为 U_{jn} , U_{jn} 是由确定项 V_{jn} 和随机项 ε_{jn} 两部分组成, 假设随机项是独立且均服从 Gumble 分布的, $F(\varepsilon_{jn}) = \exp[-\exp(-\varepsilon_{jn})]$

b 为随机项则可以得到股票走势为 j 的 MNL 模型,

$$P_{jn} = \frac{\exp(bV_{jn})}{\sum_{i=1}^J \exp(bV_{in})} = \frac{1}{1 + \sum_{j \neq i} \exp(b(V_{jn} - V_{jn}))}$$


影响股票走势的因素 x_{jnl} 即我们的输入指标与确定项的关系可以表述为:

$$V_{jn} = \beta_0 + \sum_{l=1}^L \beta_l x_{jnl}$$

$$l = 1, 2, \dots, L$$

出现情形 j 的概率与效用函数 V_{jn} 的关系表示为 logit 函数形式, 如下图所示的非线性关系, 与此同时也将各种因素对于最终确定项的影响关系转化成了非线性的关系。


图 4: MNL 模型中使用的 logit 曲线



资料来源: 长江证券研究所

Logistic 模型可以看作是人工神经网络模型中的一个神经元传导部分, 预测流程如图 5 所示, 第一层的输入为各种影响因素及对应的权值 β , 权值是由最大似然法估计得到, 然后传导到激活函数, MNL 模型的激活函数就是 logit 函数。

图 5: logistic 模型预测股票走势的流程图



资料来源：长江证券研究所

MNL 模型的理论基础完善，模型的假设和逻辑简单，且可解释性强。主要缺陷在于假设输入的指标和效用函数之间是呈现线性关系，所以当选择众多指标的时候会存在共线性问题。

人工神经网络（ANN）模型

ANN 模型由大量简单的神经元相互连接，模拟人的大脑神经处理信息的方式进行信息的并行处理和非线性转换的复杂网络系统，它是以经验最小化原则进行的。常见的神经网络模型都是呈现多层前向型，由一个输入层、数个隐藏层和一个输出层组成。理论上已经证明具有一个隐含层的三层网络可以逼近任意非线性函数。本文使用的是较为常见的 BP 神经网络模型。BP 神经网络预测逻辑是在正向传播过程中，输入因素及权值不变，通过比较最终的输出结果与真实值之间的差距来反向调整权值。

神经网络中权值的优化算法一般都是使用梯度下降，训练集中的样本形如：

$[\mathbf{x}, \mathbf{y}] = [(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{n_0})^T, (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_{n_K})^T]$ 。输入包含 n_0 个值，目标值包含 n_K ，分别对应神经网络的输入/输出维度。

将训练集中的样本一个接一个提交给神经网络，神经网络对样本输入 \mathbf{x} 计算输出 \mathbf{y} ，然后计算样本目标值与输出的平方和误差。

$$E = \frac{1}{2} \sum_{i=1}^{n_K} (\bar{y}_i - y_i)^2 = \frac{1}{2} (\bar{\mathbf{y}} - \mathbf{y})^T (\bar{\mathbf{y}} - \mathbf{y})$$

视输入 \mathbf{x} 为固定值，把 E 当作全体权值 $\mathbf{W} = \{w_{ji}^{(k)}\}$ 的函数。梯度向量 ∇E 由 E 对每一

个权重 $w_{ji}^{(k)}$ 的偏导数 $\frac{\partial E}{\partial w_{ji}^{(k)}}$ 构成，然后用下式更新全体权值：

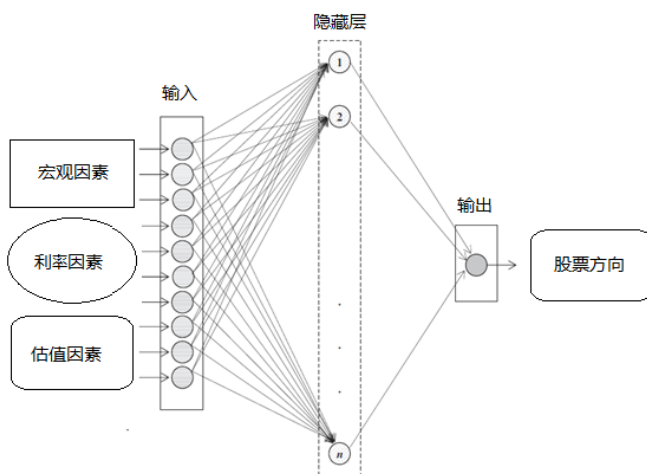
$$\begin{aligned} \mathbf{W}(s+1) &= \mathbf{W}(s) - \eta \nabla E \\ w_{ji}^{(k)}(s+1) &= w_{ji}^{(k)}(s) - \eta \frac{\partial E}{\partial w_{ji}^{(k)}} \end{aligned}$$

其中， η 是步长， s 是迭代次数。

对每一个提交给神经网络的样本用式进行一次权值更新，直到对所有样本的平均 E 值 MSE (mean square error) 小于一个预设的小阈值，此时训练完成。也可以将一批样本(mini-batch)在同样的权值 W 下计算 ∇E ，然后根据这一批 ∇E 的平均值更新 W 。

隐藏层是激活函数，一般都是使用 Sigmoid 函数。下面的神经网络流程图可以看作是由图 5 的一个个神经元结构组合而成的。

图 6: BP 神经网络模型预测股票走势的流程图



资料来源：长江证券研究所

神经网络模型理论上可以解决一系列不能用函数表达的分类回归问题，具有自学习和联想储存功能，但是其实现过程复杂，激活函数的选择、隐藏层的数目、神经元的个数、训练数据的大小、学习速率的设定等会对预测结果造成很大的影响，并且容易陷入局部最优，而导致训练集外的预测效果不佳。

支持向量机（SVM）模型

支持向量机模型有严密的统计学基础，其最初起源就是用于对于数据分类的处理，核心逻辑是构造一个决策面，在最小化经验风险及置信区间下，使训练集中的点距离该分隔平面尽可能远。对于线性不可分的数据，则可以通过非线性变换将原始空间内数据投射到高维空间，在变换空间求解最优分类面。

对于训练集内的一组样本数据，输入矩阵 $x_i \in R^d (i = 1, 2, \dots, N)$ ，对应的类别标签为 $y_i \in \{+1, -1\} (i = 1, 2, \dots, N)$ 。将在原始平面内线性不可分的矩阵 x_i 投影到一个可分的高维空间中，投影过程通过核函数 $K(x, x_i)$ 来实现，此时对投射数据进行分类的超平面需要满足：

$$y_i [w^T \cdot K(x, x_i) + b] \geq 1$$

任意一个点 x_i 到超平面的距离为：

$$d(x_i, w, b) = \frac{|w^T \cdot K(x, x_i) + b|}{\|w\|^2}$$


我们将点到这个超平面的最短距离即 $\frac{2}{\|w\|^2}$ 称为缘分离，最优分类超平面需要将两类数据区分得越开越好，这是通过最大化缘分离来实现。由于现实中不会存在完美的可分情况，因此可以引入松弛变量 ξ 和惩罚因子 C ($C > 0$ 是一个常数) 来放松优化的条件，所以现在问题转换为：

$$\min \phi(w, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t.} \begin{cases} \xi_i \geq 0 \\ y_i [w^T \cdot K(x \cdot x_i) + b] \geq 1 - \xi_i \end{cases}$$

通过拉格朗日乘数法求解这个最优式，即可得到最优分类超平面的确定式。

图 7：SVM 模型分类原理示意图



资料来源：长江证券研究所


在空间转换的时候常用的核函数有以下三种：

多项式核函数： $K(x_i \cdot x_j) = (< x_i \cdot x_j > + 1)^d$ ，对应 SVM 是一个 d 阶多项式分类器。

径向基核函数： $K(x_i \cdot x_j) = \exp(-\gamma \|x_i - x_j\|^2)$ ，对应的空间是无穷维的，有限样本数据在该空间也是线性可分的。最常用的一种方法，本文中也是使用这种方法。

Sigmoid 核函数： $K(x_i \cdot x_j) = \tanh(v < x_i \cdot x_j > + c)$ ，SVM 实现的就是一个两层感知神经网络，网络的权值、隐藏节点数目是由算法自动决定的。

图 8: SVM 模型在非线性可分下的映射逻辑



资料来源：长江证券研究所

相比较神经网络模型，SVM 对样本量没有要求，可以在有限样本的情况下获得最优解，也不需要像神经网络那样反复的确定网络结构，具有更好的泛化能力，但是其在使用过程中核函数及相关参数的选择对预测结果影响较大。

预测的结果展示和分析

模型的输入指标及参数设定

上一部分简单的介绍了机器学习方法及我们选用的三种模型之间的差异，为了找出适合国内市场的预测模型，将选取相同的训练集及输入变量，遍历三个模型，将训练集外的预测胜率作为评判优劣的标准。

- 预测的目标：时间区间为 2005 年 5 月份到 2017 年 3 月份（130 个月），沪深 300 指数的月度走势，分为上涨和下跌两种；
- 输入的指标：估值指标（月末值\变化值\均值）、利率指标、宏观经济指标、所有指标；
- 训练集选择：12 个月、18 个月、24 个月、30 个月、36 个月；
- 预测规则：采取训练集滚动的方式进行预测，例如第 1~12 个月数据训练后用于预测第 13 个月的大盘走势；
- 模型参数设定：在训练集内随机选择 80% 数据作为次训练集，剩下 20% 作为次测试集，根据选取输入指标的个数不同，选择不同的参数范围进行遍历优化。

其中由于估值指标是日频率，因此可以有三种方式转换成月频，取增量、均值或者月末数值，总共 17 个指标。每组指标选取 5 组不同长度的训练集数据测算。

表 3：模型参数的选择

模型	核函数/激活函数	参数	取值
SVM	径向基核函数	惩罚因子	0.1~10
		Gamma	指标个数的倒数
ANN	Sigmoid函数	隐藏层层数	1~2
		中间变量个数	5~10
		训练步长	1000
		mini-batch	20

资料来源：长江证券研究所

模型的预测结果

选定最优参数之后，三个模型根据输入的指标和选择的训练集，总共可以得到 90 组预测结果，以训练集外的预测结果准确度作为指标，选出了以下五组准确度最高的结果。

表 4：预测准确率最高的五组结果

输入的指标	模型	训练长度(月)	收益率	沪深300	超额收益率	预测准确度
估值指标	SVM	12	8.58%	8.88%	-0.30%	0.6016
宏观指标	SVM	12	11.42%	8.88%	2.54%	0.6094
全部指标	MNL	30	9.92%	-4.64%	14.56%	0.6182
全部指标	MNL	36	17.36%	2.48%	14.87%	0.6538
全部指标	SVM	12	8.70%	8.88%	-0.17%	0.5938

资料来源：Wind，长江证券研究所

由于是进行月度预测训练集内样本点的个数较少，效果较好的模型是 MNL 模型和 SVM 模型，神经网络模型在这个样本数据下面表现较差。模型的样本外预测准确度均在 60% 左右，但盈亏比方面并无优势，均在 1 附近。

将不同训练长度下模型的择时后净值与基准沪深 300 进行比较，可以得到如下的走势图。

图 9：SVM 模型预测区间内净值曲线走势



资料来源：Wind，长江证券研究所

SVM 模型整体来说效果一般，无法在较大下跌处帮助止损，但是在震荡下行空间会出现持续的卖空信号，能够规避一定的风险。

图 10: MNL 模型训练长度 30 个月时的净值曲线走势



资料来源：Wind，长江证券研究所

图 11: MNL 模型训练长度 36 个月时的净值曲线走势



资料来源：Wind，长江证券研究所

从表现最优的五个模型来看，从 2010 年到 2013 年期间所有模型几乎都是全段时间选择空仓，模型的输入变量和预测频率使得其无法捕捉这种时间长度大趋势下跌下的小反弹。

将最优组合拿出来看，从 08 年 7 月份开始计算每一年的累计收益率并且与同时段的沪深 300 累计收益率作比较，年化收益率和最大回撤与基准相比均有较大改善。

表 5: 最优组的分年情况

年份	收益率	基准收益率	超额收益率	夏普比率	最大回撤	基准最大回撤
2008	9.99%	-34.89%	44.88%	0.96	7.92%	46.01%
2009	71.44%	96.71%	-25.27%	2.32	25.26%	25.26%
2010	-10.39%	-12.51%	2.12%	-1.61	10.55%	29.73%
2011	3.56%	-25.01%	28.57%	0.40	7.87%	31.64%
2012	0.00%	7.55%	-7.55%	0.00	0.00%	22.41%
2013	6.25%	-7.65%	13.90%	0.55	9.66%	22.16%
2014	51.66%	51.66%	0.00%	2.78	10.43%	10.43%
2015	13.38%	5.58%	7.80%	0.41	33.25%	43.48%
2016	20.06%	-11.28%	31.34%	1.94	7.50%	23.51%
2017	4.31%	4.31%	0.00%	4.20	1.50%	1.50%
全部	17.36%	2.48%	14.87%	0.94	33.24%	46.70%

资料来源：Wind，长江证券研究所

显著性检验

显著性检验从模型和输入指标两个方面来看，模型的显著性检验主要是为了验证预测效果的参考价值。指标的显著性检验可以用于衡量不同指标对于预测效果影响的大小，也可以一定程度上降低指标共线性的干扰。

模型的显著性

模型的效果除了直接从预测的准确度判断外，也可以用 ROC 曲线及 AUC 值做直观上的比较。ROC 的全名叫做 Receiver Operating Characteristic，对分类预测模型而言，

存在一个阈值，当模型得到的结果大于这个阈值时分到 A 类，如果减小阈值当然可以使得分到 A 类的准确率上升但是与此同时误判率也会上升，ROC 曲线的横坐标就是误判率 (FPR)，纵坐标则是准确率 (TPR)。图 12 中的 ROC 曲线的横坐标用的 (1-误判率)，整个曲线越接近定点 (1, 1) 的位置，说明模型预测的效果越好。


ROC 曲线下面的面积即 AUC 值，同理 AUC 值越接近 1 代表模型预测效果越好，下面列举了三组模型的 AUC 值，效果最好的对应的就是准确度较高的训练长度为 36 个月的 MNL 模型。

表 6：三种模型的 AUC 值展示

输入的指标	模型	训练长度 (月)	AUC 值
全部指标	MNL	36	0.656
全部指标	MNL	30	0.619
全部指标	SVM	12	0.608

资料来源：Wind，长江证券研究所

图 12：三种模型的 ROC 曲线



资料来源：Wind，长江证券研究所


输入指标的显著性

选择不同类型的指标构建的模型中预测准确率超过 50% 的模型，统计其 2 输入指标类别出现的频次，估值类指标效果最好。

不同指标在模型中显著度频率见图 12，单个指标来看市净率、10 年期国债收益率及 GDP 表现较好。大部分指标表现都较为显著，并无特别大的区别，也解释了为什么选择全部指标输入的模型效果最好。


这种每期根据各个指标的显著性选择输入指标的模型其预测准确度并未优于固定输入指标的效果，因此在实际的预测过程中，可以根据需求采取固定的指标输入来进行预测。

图 13: 不同指标类别的显著性水平



资料来源: Wind, 长江证券研究所

图 14: 显著性排名前十的指标



资料来源: Wind, 长江证券研究所

多分类下的模型预测效果

我们判断股票趋势的目的是辅助各种资产配置模型进行决策, 通过上节展示可以看到使用机器学习模型可以取得较好择时效果。此外机器学习还有一般趋势判断的方法没有的优势, 可以对预测的结果进行进一步细分, 即根据涨跌的幅度来分成更细的类别。

四分类下的预测效果

进行四分类划分时, 按照大幅上涨、大幅下跌、小幅上涨、小幅下跌来进行细分, 选取分档阈值的时候尽量保持每种档位的出现频率相当, 可以在分成四类的时候依据训练期内股票上涨和下跌的收益率序列的二分位位置选择每期的阈值或者是依据历史数据选择较为合理的固定阈值。

表 7: 预测准确率最高的五组结果

输入的指标	模型	训练长度(月)	收益率	沪深300	超额收益率	预测准确度
估值-增长	SVM	12	12.56%	8.88%	3.69%	0.6172
宏观指标	ANN	30	-0.06%	-4.64%	4.59%	0.6000
宏观指标	SVM	12	15.64%	8.88%	6.76%	0.6172
全部指标	ANN	36	4.62%	2.48%	2.14%	0.5962
全部指标	MNL	36	17.44%	2.48%	14.95%	0.6442

资料来源: Wind, 长江证券研究所

表 6 是依据分成四类之后的情况选出的准确度在前五的几个模型, 可以观察到最优模型仍然是训练长度为 36 个月的 MNL 模型, 整体而言由于细分类之后每类的样本数据变少的原因预测准确度会有所下降。

图 15：四分类下 ANN 模型训练长度 30 个月时的预测效果




资料来源：Wind，长江证券研究所

图 16：四分类下 SVM 模型训练长度 12 个月时的预测效果




资料来源：Wind，长江证券研究所

图 17：四分类下 ANN 模型训练长度 36 个月时的预测效果



资料来源：Wind，长江证券研究所

图 18：四分类下 MNL 模型训练长度 36 个月时的预测效果



资料来源：Wind，长江证券研究所

但是 MNL 模型的效果在四分类下获取了更高的盈亏比，表现为最后年化收益率有所上升，由 17.36% 上升到 17.44%。

表 8：最优组的分年情况

年份	收益率	基准收益率	超额收益率	夏普比率	最大回撤	基准最大回撤
2008	7.63%	-34.89%	44.88%	0.96	7.63%	46.01%
2009	28.04%	96.71%	-25.27%	3.10	28.04%	25.26%
2010	17.70%	-12.51%	2.12%	-0.34	17.70%	29.73%
2011	6.08%	-25.01%	28.57%	0.67	6.08%	31.64%
2012	0.00%	7.55%	-7.55%	0.00	0.00%	22.41%
2013	18.39%	-7.65%	13.90%	-0.65	18.39%	22.16%
2014	10.33%	51.66%	0.00%	2.78	10.33%	10.43%
2015	36.23%	5.58%	7.80%	0.63	36.23%	43.48%
2016	6.93%	-11.28%	31.34%	1.38	6.93%	23.51%
2017	0.00%	4.31%	0.00%	0.00	0.00%	1.50%
全部	17.44%	2.48%	14.95%	0.90	31.58%	46.70%

资料来源：Wind，长江证券研究所

四分类下的分组效果以及胜率均是采取类似于二分类下的计算方式，大幅上涨和小幅上涨对应的预测结果就是指数上涨，其在单独用于判断股票走势的时候虽然与二分类相比

并无太大改善，但是在运用风险平价、Black Litterman 等配置模型可以根据预测出的幅度大小来调整风险预算或给出主观观点。具体应用将在下篇报告中阐述。

六分类下的预测效果

我们也尝试在分成六类下的情况下进行预测，即按照上涨和下跌的幅度进一步细分，同样筛选出预测准确度最高的五组。

分成六类后预测准确度明显下降，主要原因是此时不同类型下的样本数量更少，导致模型的训练效果不佳，整体的超额收益率也大大降低。再次说明了样本数量是局限机器学习模型发挥其功效的主要因素之一。

表 9：预测准确率最高的五组结果

输入的指标	模型	训练长度(月)	收益率	沪深300	超额收益率	预测准确度
估值-增长	ANN	30	-2.68%	-4.64%	1.96%	0.5818
估值-增长	MNL	18	7.21%	5.31%	1.89%	0.6148
估值-增长	MNL	24	6.42%	-0.89%	7.31%	0.5862
估值-增长	SVM	12	10.09%	8.88%	1.21%	0.5781
宏观指标	ANN	36	-6.68%	2.48%	-9.16%	0.5962

资料来源：Wind，长江证券研究所

其他股票指数上的预测效果

前面部分所有预测结果主要是依据沪深 300 指数及其相关指标进行，从风格上划分沪深 300 指数主要是代表了偏大盘股票走势，但是其他主要股票指数如中证 500 及中证 1000 同沪深 300 的走势一致性非常高，因此，这部分将直接拿沪深 300 的预测结果用于中证 500 和中证 1000 的趋势判断，来观察预测效果。由于六分类的预测效果不佳，因此只进行二分类及四分类下的测算。

表 10：二分类下对中证 500 和中证 1000 的预测效果

输入的指标	模型	训练长度(月)	收益率(中证500)	超额收益率	盈亏比	收益率(中证1000)	超额收益率	盈亏比
估值指标	SVM	12	9.00%	-5.76%	0.95	9.80%	-9.15%	1.06
宏观指标	SVM	12	12.75%	-2.01%	1.07	14.14%	-4.81%	1.18
全部指标	MNL	30	15.90%	12.96%	0.82	18.33%	11.11%	1.01
全部指标	MNL	36	26.71%	16.66%	1.20	28.92%	14.16%	1.24
全部指标	SVM	12	10.29%	-4.47%	0.96	12.14%	-6.81%	1.10

资料来源：Wind，长江证券研究所

整体而言，对于沪深 300 的预测结果放在中证 500 和中证 1000 上效果也较好，能够获取比单纯沪深 300 预测更好的绝对收益，表现在盈亏比上有一定程度提升，从 0.98 提升到了 1.2。

二分类和四分类下，效果最好的依然是 MNL 模型，并且此时四分类下的中证 500 和中证 1000 预测的超额收益较二分类分别提升了 2.74%和 5.02%。

表 11：四分类下对中证 500 和中证 1000 的预测效果

输入的指标	模型	训练长度（月）	收益率(中证500)	超额收益率	盈亏比	收益率(中证1000)	超额收益率	盈亏比
估值-增长	SVM	12	15.73%	0.97%	1.08	17.36%	-1.59%	1.25
宏观指标	ANN	30	7.45%	4.51%	0.88	10.45%	3.23%	1.07
宏观指标	SVM	12	15.28%	0.53%	1.02	17.62%	-1.33%	1.15
全部指标	ANN	36	15.25%	5.21%	1.09	17.67%	2.91%	1.28
全部指标	MNL	36	29.44%	19.40%	1.04	33.94%	19.18%	1.28

资料来源：Wind，长江证券研究所

从绝对收益的角度来看，中证 500 和中证 1000 在相同时期内收益率比沪深 300 高很多，不同风格轮动配置的价值凸显。在大部分机构和个人投资者配置海外权益资产的权重有限的时候，将国内权益资产在趋势判断的基础上进行风格轮动配置可以一定程度上提高收益平滑波动。表 11 中就简单的通过三种指数等权的方式对加入趋势判断后的效果进行测算，夏普比率及 Calmar 比率都有了显著性的提高。

表 12：加入趋势判断后三种指数等权重组合的效果

输入的指标	年化收益率	夏普比率	最大回撤	Calmar比率
等权重组合	9.69%	0.33	50.98%	0.19
预测后等权重组合	25.45%	1.27	40.25%	0.63

资料来源：Wind，长江证券研究所

总结全文，作为大类资产配置相关的第二篇报告，开篇首先是将大类资产配置做了系统上的梳理，在运用配置模型之前，每一类资产实际上都可以分成更细的类别先进行大类下的优化，所以后面大量篇幅是着眼于国内股票类资产的趋势判断，运用了机器学习方法对沪深 300 月度走势作出上涨和下跌预测，比较了三种常见模型，其中训练期为 36 个月的 MNL 模型表现结果最佳；另外还测算了更细致的分类结果下的预测效果，将上涨和下跌按照幅度大小分为四类和六类，其中仍然是训练期为 36 个月的 MNL 模型效果较好，表现了模型预测上的稳健性。

在大类资产配置的应用上，最直接的方式是将预测的结果作为股票类资产权重增减的参考指标；其次，对于很多配置模型例如风险平价模型和 Black-Litterman 模型，其中都可以加入对资产收益率的主观判断，利用模型预测的结果及概率大小可以直接拿到配置模型中使用；再者，通过扩充指标库，总结出影响其他资产走势的因素，可以将模型预测的方法应用于其他资产类别的趋势判断中，进一步加强对每一个大类资产走势的掌控。

投资评级说明

行业评级	报告发布日后的 12 个月内行业股票指数的涨跌幅度相对同期沪深 300 指数的涨跌幅为基准，投资建议的评级标准为：
看好	相对表现优于市场
中性	相对表现与市场持平
看淡	相对表现弱于市场
公司评级	报告发布日后的 12 个月内公司的涨跌幅度相对同期沪深 300 指数的涨跌幅为基准，投资建议的评级标准为：
买入	相对大盘涨幅大于 10%
增持	相对大盘涨幅在 5%~10%之间
中性	相对大盘涨幅在-5%~5%之间
减持	相对大盘涨幅小于-5%
无投资评级	由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级。

联系我们

上海

浦东新区世纪大道 1589 号长泰国际金融大厦 21 楼（200122）

武汉

武汉市新华路特 8 号长江证券大厦 11 楼（430015）

北京

西城区金融街 33 号通泰大厦 15 层（100032）

深圳

深圳市福田区福华一路 6 号免税商务大厦 18 楼（518000）

重要声明

长江证券股份有限公司具有证券投资咨询业务资格，经营证券业务许可证编号：10060000。

本报告的作者是基于独立、客观、公正和审慎的原则制作本研究报告。本报告的信息均来源于公开资料，本公司对这些信息的准确性和完整性不作任何保证，也不保证所包含信息和建议不发生任何变更。本公司已力求报告内容的客观、公正，但文中的观点、结论和建议仅供参考，不包含作者对证券价格涨跌或市场走势的确定性判断。报告中的信息或意见并不构成所述证券的买卖出价或征价，投资者据此做出的任何投资决策与本公司和作者无关。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司及作者在自身所知范围内，与本报告中所评价或推荐的证券不存在法律法规要求披露或采取限制、静默措施的利益冲突。

本报告版权仅仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制和发布。如引用须注明出处为长江证券研究所，且不得对本报告进行有悖原意的引用、删节和修改。刊载或者转发本证券研究报告或者摘要的，应当注明本报告的发布人和发布日期，提示使用证券研究报告的风险。未经授权刊载或者转发本报告的，本公司将保留向其追究法律责任的权利。